

목차

1. 프로젝트 목적 및 과정
2. 데이터셋 소개
3. 데이터 전처리 및 EDA
 - 3.1. 각 feature의 data type, 기초통계량 확인, 이상치 제거
 - 3.2. EDA(탐색적 데이터 분석)
 - 3.2.1. 수치형 변수의 분포 분석
 - 3.2.2. 범주형 변수의 분포(frequency) 분석
 - 3.2.3. 수치형 변수 간 이변량 분석
 - 3.2.4. 수치형, 범주형 변수 조합의 kdeplot 분석
 - 3.2.5. 범주형 변수 간의 관계 분석
 - 3.2.6. 다변량 분석

목차

- 4. 정규화(Min-Max Scaling)
- 5. 초기 군집 수 결정
 - 5.1. Elbow method
 - 5.2. Silhouette
- 6. PCA를 이용한 시각화
- 7. 각 Cluster의 특성 정리
- 8. Classification(지도학습) – DecisionTree
- 9. 결론

1. 프로젝트 목적 및 과정

★ 프로젝트 목적

Kaggle의 쇼핑몰 고객 dataset을 K-means 알고리즘을 이용해 각 군집의 고객 특성 분석

★ 프로젝트 과정

1. EDA(탐색적 데이터 분석) 수행
2. Data Preprocessing(데이터 전처리) for K-means clustering
3. 초기 군집 수 결정을 위한 Elbow-method, Silhouette기법을 이용
4. K-means clustering 적용 후, 각 군집의 고객 특성 분석 및 결과 해석

2. 데이터셋 소개

- Segmentation data 상위 10개 -

	A	B	C	D	E	F	G	H
1	ID	Sex	Marital status	Age	Education	Income	Occupation	Settlement size
2	100000001	0	0	67	2	124670	1	2
3	100000002	1	1	22	1	150773	1	2
4	100000003	0	0	49	1	89210	0	0
5	100000004	0	0	45	1	171565	1	1
6	100000005	0	0	53	1	149031	1	1
7	100000006	0	0	35	1	144848	0	0
8	100000007	0	0	53	1	156495	1	1
9	100000008	0	0	35	1	193621	2	1
10	100000009	0	1	61	2	151591	0	0

2. 데이터셋 소개

Variable	Data type	Range	Description
ID	Numerical	Integer	고객의 고유 ID
Sex	Categorical	{0, 1}	성별 0 – male 1 – female
Marital status	Categorical	{0, 1}	고객의 결혼 상태 0 – single 1 – non-single(divorced / separated / married / widowed)
Age	Numerical	Integer	나이 Min value – 18세 Max value – 76세
Education	Categorical	{0, 1, 2, 3}	고객의 (최종)교육 수준 0 – other / unknown (나머지 / 모르는 경우) 1 – high school (고등학교 졸업) 2 – university (대학 졸업) 3 – graduate school (대학원 졸업)

2. 데이터셋 소개

Variable	Data type	Range	Description
Income	Numerical	Real	수입(단위: US dollars) Min value – 35832\$ Max value – 309364\$
Occupation	Categorical	{0, 1, 2}	직업 0 – unemployed / unskilled 1 – skilled employee / official 2 – management / self-employed / highly qualified employee / officer
Settlement size	Categorical	{0, 1, 2}	고객이 살고 있는 도시의 규모 0 - small city 1 – mid-sized city 2 – big city

2. 데이터셋 소개

Variable	Data type	Range	Description
Income	Numerical	Real	수입(단위: US dollars) Min value – 35832\$ Max value – 309364\$
Occupation	Categorical	{0, 1, 2}	직업 0 – unemployed / unskilled 1 – skilled employee / official 2 – management / self-employed / highly qualified employee / officer
Settlement size	Categorical	{0, 1, 2}	고객이 살고 있는 도시의 규모 0 - small city 1 – mid-sized city 2 – big city

3. 데이터 전처리 및 EDA

3.1. 각 feature의 data type, 기초통계량 확인, 이상치 제거

3. 데이터 전처리 및 EDA

3.2. EDA(탐색적 데이터 분석)

3.2.1. 수치형 변수의 분포 분석


★ 수치형 변수의 분포 결과

- Age는 오른쪽 꼬리가 긴(왜도>0) 분포
- Income은 정규분포에 가까워 보임


★ 정규성 검정의 결과

: 두 분포 모두 정규분포 가정의 귀무가설 p-value가 $4e-05$, $1.7e-54$ 로 정규분포를 따르지 않음

Age 분포



Income 분포



3. 데이터 전처리 및 EDA






3.2. EDA(탐색적 데이터 분석)

3.2.2. 범주형 변수의 분포(frequency) 분석

★ 범주형 변수의 분포 결과

: Education에서 1(고졸)이 약 70.7%를 차지

-> 2, 3(고학력자)는 하나로 생각할 수도 있어보임





3. 데이터 전처리 및 EDA

3.2. EDA(탐색적 데이터 분석)

3.2.3. 수치형 변수 간 이변량 분석

★ 이변량 분석 결과

- Age와 Income의 상관계수가 0.32로 약한 양의 상관관계



3. 데이터 전처리 및 EDA

3.2. EDA(탐색적 데이터 분석)

3.2.4. 수치형, 범주형 변수 조합의 kdeplot 분석

★ 수치형, 범주형 변수 관계 결과

- Age와 Martial Status사이에서 1(non-single)의 Age가 0(single)의 평균 Age보다 어림을 알 수 있음
- Age과 Education 사이에서 1(high school)의 비율이 20~40대에 집중 분포해있고, 2(university)는 40대 이상에서 분포해있음
- Occupation은 전체적으로 20-30대에 집중 분포해있고 나이가 많아질수록 적어짐
- Occupation 수준이 올라갈 수록 평균 수입은 높아짐
- Income과 Settlement size 사이에서 0(small city)에서 저소득 비율을 다수 차지하는 걸로 보임

★ Insight: 군집화 후 각 군집에 20~30대가 다수 분포해 있고, small city일 경우 저소득인 군집이 생길 가능성이 많음

3. 데이터 전처리 및 EDA

3.2. EDA(탐색적 데이터 분석)

3.2.5. 범주형 변수 간의 관계 분석

★ 범주형 변수 간의 관계 결과

- 남자가 여자보다 싱글이 더 많음 -> 여자가 더 결혼을 많이 함
- 여자가 더 작은 도시에 사는 경향이 있음
- 싱글이 아닌 사람들이 고등학교 이상의 수준의 교육을 받는 경향이 있음, 0(고졸 미만)은 없음
- 싱글이 아닌 사람들이 싱글인 사람보다 더 작은 도시에 사는 경향이 있음
- Occupataion=0(무직)인 사람들은 거의 소도시에 산다고 볼 수 있음

3. 데이터 전처리 및 EDA

3.2. EDA(탐색적 데이터 분석)

3.2.6. 다변량 분석

★ 다변량 분석 결과

- 작은 도시에 살 수록 소득이 낮은 경향을 보임
- 직업의 수준이 높을 수록 소득이 높음
- 고학력자(Education=2,3)는 나이가 많지만 소득에 영향을 끼치지 않는 것 같아 보임
- 싱글이 아닐 수록 나이가 젊고 소득이 적은 경향이 있음
- 남자가 여자보다 평균적으로 나이가 많을 수록 소득이 높은 경향이 있음

4. 정규화(Min-Max Scaling)

★ 정규화를 하는 이유: 각 feature의 Scale을 일정한 범위로 조절하여 각 feature에 대한 중요성을 동등하게 부여하기 위함이다.

★ Min-Max정규화는 Outlier에 민감하지만, 처음에 Outlier를 제거했기 때문에 Min-max정규화를 사용해도 무방하다고 판단.

```
from sklearn.preprocessing import MinMaxScaler
```


```
scaler = MinMaxScaler()  
X = scaler.fit_transform(data)
```

5. 초기 군집 수 결정

5.1. Elbow method

★ Elbow method 결과

최적 군집 수 = 6




5. 초기 군집 수 결정

5.2. Silhouette

★ Silhouette 결과

최적 군집 수 = 7

결론: 초기 군집 수는 6으로 설정



6. PCA를 이용한 시각화

★ 시각화를 위한 PCA 주성분 개수 선정

```
from sklearn.decomposition import PCA
```


```
pca = PCA(n_components=3, random_state=42)  
X_pca = pca.fit_transform(X)
```

```
X_pca_df = pd.DataFrame(data=X_pca, columns=['X1', 'X2', 'X3'])
```

```
print(pca.explained_variance_ratio_)
```

```
[0.44636151 0.23639792 0.10678002]
```

- PCA의 component를 3개로 하면 설명력이 **약 79%** 정도 되므로 **주성분 3개로** 차원 축소하여 시각화를 진행



7. 각 Cluster의 특성 정리

Cluster 0

1. 남성
2. 미혼
3. 20-40대
4. 고졸 또는 그 이하가 대부분인
교육 수준
5. 중간소득
6. 약 67% 정도 무직
7. 소도시에 거주

Cluster 1

1. 남성
2. 기혼
3. 주로 20~30대
4. 고졸 대부분과
고학력자(대학교, 대학원) 존재
5. 중간소득
6. 직원/공무원 근무자가 대다수
7. 소도시, 중간, 대도시
비교적 고루 분포

Cluster 2

1. 남성
2. 미혼
3. 30~40대
4. 대부분 고졸 교육수준
5. 중간소득
6. 직원 / 공무원 근무자
7. 중간 도시와 대도시 거주

7. 각 Cluster의 특성 정리

Cluster 3

1. 여성
2. 기혼
3. 20~30대
4. 고졸이 대부분,
고학력자(대학교, 대학원)존재
5. 중간소득
6. 직원/공무원
7. 중간도시, 대도시 거주

Cluster 4

1. 여성
2. 미혼
3. 20~40대
4. 대부분 고졸 교육수준
5. 저소득
6. 대부분 무직
7. 소도시 거주

Cluster 5

1. 여성
2. 기혼
3. 20~30대
4. 대부분 고졸 교육수준
5. 중간소득
6. 무직과 직장/공무원 근로자가
거의 균일하게 존재
7. 소도시 거주

8 Classification(지도학습) - DecisionTree

★ 군집화로 나온 Label을 바탕으로 Classification을 하여 Clustering 결과와 비교 -> Accuracy 측정

★ Accuracy = 0.99로 거의 동일하게 예측이 되었고, Classification의 분류 기준이 Clustering의 특성을 구체화하는 것에 도움이 될 수 있다.

```
from sklearn.tree import DecisionTreeClassifier
from sklearn import tree
import graphviz
```

```
clf = DecisionTreeClassifier(max_depth = 4, min_samples_leaf = 5)
# max_depth는 가지를 치는 횟수, min_smamples_leaf = 5는 분류를 했을 때 sample수가 5면 더 이상 가지를 치지 않는다.
```

```
X_clusters = results_df.drop('Labels', axis=1)
y_clusters = results_df['Labels']
```

```
clf.fit(X_clusters, y_clusters)
```


```
DecisionTreeClassifier
DecisionTreeClassifier(max_depth=4, min_samples_leaf=5)
```

Confusion Matrix

```
[[308  0  0  0  0  0]
 [  0 246  0  0  0  0]
 [ 10  0 461  0  0  0]
 [  0  0  0 290  0  1]
 [  0  0  0  0 177  0]
 [  0  0  0  4  0 420]]
```

	precision	recall	f1-score	support
0	0.97	1.00	0.98	308
1	1.00	1.00	1.00	246
2	1.00	0.98	0.99	471
3	0.99	1.00	0.99	291
4	1.00	1.00	1.00	177
5	1.00	0.99	0.99	424
accuracy			0.99	1917
macro avg	0.99	0.99	0.99	1917
weighted avg	0.99	0.99	0.99	1917

8 Classification(지도학습) - DecisionTree



9. 결론

★ 각 Cluster의 대표 특성 요약

- Cluster 0 : 싱글 + 남성 + 소도시 + 미취업자/취업자(employee/self-employed)
- Cluster 1 : 비 싱글 + 남성
- Cluster 2 : 싱글 + 남성 + 중/대도시 + 취업자(employee/self-employed)
- Cluster 3 : 비 싱글 + 여성 + 중/대도시 + 취업자(management/self-employed)
- Cluster 4 : 싱글 + 여성 + 소도시
- Cluster 5 : 비 싱글 + 여성 + 소도시