

목차

1. 새로운 Clustering 방법 소개
2. K-prototype Clustering 적용
3. K-means Clustering 결과와 비교

1. 새로운 Clustering 방법 소개

★ K-prototype Clustering

1. 수치형 변수와 범주형 변수가 같이 있을 때 사용할 수 있는 Clustering
2. 범주형 변수의 Encoding과정 없이 빈도 값을 이용하여 Clustering 할 수 있음
3. K-means와 K-modes 기법이 혼합된 형태

1. 새로운 Clustering 방법 소개

★ K-prototype Clustering

★ 단계

1단계 : k개의 초기 군집으로 데이터를 할당

2단계 : 각 군집의 중심값을 계산

연속형 변수의 평균값과 범주형 변수의
최빈값으로 중심값 선정

3단계: 군집의 중심값과 가장 가까운 데이터를 군집에 재할당

4단계: 종료 조건이 만족할 때까지 2,3 단계 반복

$$d_{K-Prototypes} = d_{K-Means} + \lambda d_{K-Modes}$$
$$= d_{euclid}(X_i, C_j)^2 + \lambda d_{simple\ matching}(X_i, C_j)$$

가중치

거리 = 유클리디안 거리 (연속형 변수) + 가중치 x 비유사도(범주형 변수)

2. K-prototype Clustering 적용

★ Cluster=6으로 K-prototype 적용

```
!pip install kmodes
from kmodes.kprototypes import KPrototypes

kp = KPrototypes(n_clusters=6, init="Huang", n_init=10, verbose=False, random_state=42,)
clusters = kp.fit_predict(
    data_ri.drop(["ID"], axis=1),
    categorical=[0,1,2,3,4], # 어떤 열이 범주형 변수인지!
)
print(kp.gamma)
print(clusters) # 소속
print(kp.cluster_centroids_) # 중심점
```

```
0.09631678285090889
[4 3 1 ... 1 0 1]
[['0.2065670986162972' '0.2959877977055841' '1' '1' '1' '0' '0']
 ['0.35371674024579336' '0.32720210612218725' '0' '0' '1' '0' '0']
 ['0.32497064161417727' '0.6016948479299945' '0' '0' '1' '1' '2']
 ['0.18020487664117738' '0.5020449672301944' '1' '1' '1' '1' '0']
 ['0.6642793987621562' '0.6711876341772071' '1' '1' '2' '1' '1']
 ['0.29104315766644956' '0.5756174942447138' '0' '0' '1' '1' '1']]
```

이때 적용된 가중치(λ) =
0.09631678285090889

3. K-means Clustering 결과와 비교

★ K-means

- Cluster 0 : 싱글 + 남성 + 소도시 + 미취업자/취업자(employee/self-employed)
- Cluster 1 : 비 싱글 + 남성
- Cluster 2 : 싱글 + 남성 + 중/대도시 + 취업자(employee/self-employed)
- Cluster 3 : 비 싱글 + 여성 + 중/대도시 + 취업자(management/self-employed)
- Cluster 4 : 싱글 + 여성 + 소도시
- Cluster 5 : 비 싱글 + 여성 + 소도시

★ K-prototype

- Cluster 0 : 싱글 + 남성 + 소도시 + 미취업자 + 20~30대 + 저소득
- Cluster 1 : 싱글 + 남성 + 소도시 + 미취업자 + 30대 + 저소득
- Cluster 2 : 싱글 + 남성 + 대도시 + 취업자(employee) + 20~40대 + 중간소득
- Cluster 3 : 비 싱글 + 여성 + 취업자(employee/self-employed) + 20~40대 + 중간소득
- Cluster 4 : 비 싱글 + 취업자(employee/self-employed) + 30~40대, 그 이상 + 고학력 + 고소득
- Cluster 5 : 싱글 + 여성 + 중간도시 + 취업자(employee) + 20~30대 + 중간소득